Octubre 2025

Proyecto de Grado
Maestria en Analítica Aplicada
Universidad de la Sabana

Implementación modelos de *nowcasting* electoral en contextos adversos

Elecciones presidenciales en Bolivia y Colombia

JUAN SOTELO AGUILAR

Tabla de contenido

1. Introducción: 2
b. Relevancia y Justificación 3
c. Fuentes de datos 3
d. Resultados esperados 4
e. Impacto esperado 4
2. Pregunta de investigación: 4
3. Marco conceptual 5
b. Marco teóricos: 6
c. Estado del arte: 7
Estudios en Contextos Globales 7
Estudios en América Latina 8
Limitaciones y Tendencias 8
4. Objetivo General 10
a. Objetivos Específicos 11
5. Metodología 11
a. Comprensión del problema 11
b. Comprensión de los datos 12
i. Recolección inicial de datos 13
1. Facebook 13
2. Twitter (X) 13
3. Instagram 13
4. TikTok 14
ii. Descripción de los datos: 14
c. Exploración y visualización: 14
d. Evaluación de calidad: 14
6. Impacto esperado: 16
Referencias bibliográficas: 24

Resumen:

Desde la década de 1970, los modelos predictivos paramétricos han sido herramientas clave para anticipar resultados en elecciones legislativas y ejecutivas. Sin embargo, su eficacia ha disminuido significativamente, especialmente desde 2015, debido a la creciente complejidad de los entornos electorales. En contraste, los modelos de *Machine Learning* aplicados al

análisis de redes sociales han demostrado capacidades predictivas estadísticamente significativas en regiones como Norteamérica, Europa, el sur y sudeste asiático (Singh et al., 2020). A pesar de su éxito, en Latinoamérica la investigación sobre estas metodologías es limitada, y los pocos estudios existentes se centran en elecciones presidenciales, sin abordar procesos legislativos, locales o de cuerpos colegiados.

Este proyecto busca contribuir a cerrar esta brecha mediante el análisis de datos de redes sociales, específicamente alrededor de 2.000 publicaciones en Twitter (hoy X), Instagram, Facebook y TikTok, relacionadas con las elecciones presidenciales de Bolivia del año 2025 con miras a la elección presidencial de Colombia en el 2026.

La metodología empleada integra técnicas de minería de texto y modelos de *Machine Learning*. Se realizó la recolección de las publicaciones, aplicando preprocesamiento y análisis de sentimiento a los textos. Posteriormente, se entrenaron y evaluaron modelos predictivos de tipo GRNN y MLP por ser modelos ya utilizados en Latinoamérica y que han mostrado capacidades predictivas estadísticamente significativas (Brito & Adeodato, 2022, 2023). Los resultados esperados mostrarían una capacidad predictiva alta y estadísticamente significativa para identificar tendencias en las elecciones presidenciales, evidenciando patrones específicos en el comportamiento electoral reflejado en redes sociales.

Este estudio se distingue de otros casos de uso de *nowcasting electoral* por tres motivos relevantes: 1. El fraccionamiento de candidatos a menos de 300 días antes de la elección, en el caso colombiano del 2026 la lista de la Registraduría Nacional superó los setenta candidatos. 2. El escaso tiempo antes de la elección, en comparación a la obra de Brito y Andeoato, este trabajo solo toma publicaciones a 200 días antes de las elecciones de primera vuelta y en el caso boliviano a una semana de la segunda vuelta y 3. La falta de herramientas de *big data* institucionales y el uso de herramientas comerciales de Apis. El trabajo busca comprobar si la metodología es aplicable con estas limitaciones metodológicas y circunstanciales.

Este estudio no solo amplía la comprensión del uso de *Machine Learning* en contextos electorales latinoamericanos, sino que también establece una base para investigaciones futuras sobre elecciones legislativas, locales y colegiadas en la región.

1. Introducción:

a. **Contexto:** La capacidad de predecir resultados electorales ha sido un reto constante para la ciencia política y las disciplinas afines, aunque los modelos paramétricos usados desde los 70s, que usaban encuestas junto a variables macroeconómicas, habían mostrado capacidades predictivas altas, desde el año 2015 aproximadamente, su capacidad predictiva ha prácticamente desaparecido (Mongrain, 2022; Stegmaier et al., 2023).

La crisis de los modelos paramétricos se explica por una crisis generalizada de la confianza en las encuestadoras (Kennedy et al., 2018), cambios en el estilo de la comunicación política (Tucker et al., 2020) y el advenimiento de las redes sociales ha creado ambientes políticos cada vez más homogéneos pero fragmentados (Barberá, 2020; Eady et al., 2019). A su vez, hemos visto un crecimiento exponencial en la oferta de datos relevantes para el análisis electoral (Skoric et al., 2020). Esto ha creado un agujero metodológico en la capacidad de la ciencia política de predecir y entender la mecánica interna electoral que ha sido llenado cada vez con mayor fuerza por el uso de herramientas de Machine Learning (Skoric et al., 2020).

El desarrollo de este tipo de herramientas se viene dando desde la mitad de los 2010s (Anjaria & Guddeti, 2014) y ha mostrado tener una capacidad predictiva estadísticamente significativa. Aun así, su expansión territorial ha sido limitada a Norteamérica, Europa y el Sur de Asia

(particularmente en la India) (Skoric et al., 2020), han existido pocos casos de uso en Latinoamérica (Brito & Adeodato, 2022, 2023; Zuloaga-Rotta et al., 2024) y estos se han realizado en contextos de campañas de pocos candidatos y han sido estudios con amplia financiación y oferta de información.

b. Relevancia y Justificación

El fortalecimiento de espacios comunicativos cerrados (como lo son las redes sociales) tanto dentro como fuera de Latinoamérica se ha convertido en un foco para la radicalización (Dickel & Evolvi, 2023; Marcks & Pawelz, 2022; Weimann & Masri, 2023) y la difusión de desinformación (Treen et al., 2020). Por lo menos desde el 2006 y particularmente desde el 2016, el mundo ha sufrido un declive democrático generalizado, en particular entre los países del G-20, de los cuales 19 han mostrado señales de debilitamiento de la separación de poderes, la participación democrática y la libre expresión (Diamond, 2021). En este contexto, el tener herramientas novedosas para entender los efectos de las redes sociales en la democracia en nuestro continente es el primer paso para salvaguardarla.

Hay muestras de que la democracia latinoamericana está en un franco retroceso por primera vez desde el fin de las antiguas dictaduras del siglo XX (Rovira Kaltwasser & Van Hauwaert, 2020). A su vez, este debilitamiento de la democracia, en Latinoamérica y en particular en Colombia no solo empieza con la presidencia, sino desde los poderes locales (Pachón Soto et al., 2024). Por lo tanto, dentro de las **prioridades actuales de la ciencia política actual en Latinoamérica**, está el uso de nuevas metodologías para la predicción y el entendimiento del proceso electoral.

c. Fuentes de datos

Para realizar esto, es necesario tomar una elección cuya campaña esté en curso, en este caso, las Elecciones presidenciales del 2025 y el 2026

Resultados electorales de la primera vuelta de la Elección del 2026 en Colombia. Gracias a datos del Observatorio Electoral de la Registraduría General del Estado Civil, tendremos resultados a nivel de mesa de votación para cada una de esas elecciones el mismo día de la elección. En el caso boliviano, el Órgano Electoral Plurinacional dará resultados preliminares la semana siguiente a los resultados de la votación.

Conjunto de datos de publicaciones de los 200 días anteriores a la elección en el caso colombiano y 7 días en el caso boliviano: Existen herramientas que permiten realizar procesos de web scraping en las redes sociales más usadas en Colombia: Facebook, Instagram y Twitter (We Are Social, 2024) como lo son Apify y Scrapify que por precios accesibles pueden descargar miles de publicaciones.

Otros ejemplos de web scraping en Latinoamérica han usado alrededor de 60.000 tweets en el caso de Twitter. En el caso de Brito y Andeoato (2023), se usaron 65.000 para las elecciones presidenciales de tres países, por lo que un número de alrededor de 20.000 tweets y publicaciones en Facebook sería el objetivo de los 200 días anteriores a las elecciones en el caso colombiano y alrededor de 14.000 en el caso boliviano.

Resultados de las encuestas comerciales: El Consejo Nacional Electoral en Colombia mantiene un registro abierto de todos los resultados de encuestas realizadas por encuestadoras certificadas en Colombia. Estos documentos son libres y abiertos al público y mantienen criterios de formato y ficha técnica. Aun así, el convertir estos reportes a formato tabular es una tarea que se debe hacer manual. Estas encuestas comerciales comenzarán a ser publicadas en noviembre del 2025 debido a una veda aprobada en Julio del mismo año.

En el caso boliviano, estas encuestas no están reguladas y son escasas, solo tres encuestas con criterios técnicos han sido publicadas en los medios nacionales del país.

d. Resultados esperados

Aunque el uso de Machine Learning para predecir elecciones presidenciales en Colombia ha tenido buenos resultados usando el modelo GRNN y MLP, que tuvieron resultados incluso superiores a los de las encuestadoras (Brito & Adeodato, 2023), aun así. El éxito no es asegurado, ya que hay modificaciones para hacer en los modelos propuestos para adaptarlo a un contexto de alta dispersión de candidatos y estos pueden disminuir su capacidad predictiva.

En el caso de Bolivia, por estar en segunda vuelta, la complejidad predictiva se reduce por el hecho de tener solo dos candidatos. La dificultad del modelo de nowcasting es la muy corta serie de tiempo y la falta de encuestas fácilmente comparables.

e. Impacto esperado

Esperamos que esta herramienta, adaptada y calibrada al contexto boliviano y posteriormente colombiano sirva para las campañas de congresistas y de alcaldes como base para la realización de *nowcasting* o predicción en vivo de la intención de voto. También, tendría el efecto de dar las herramientas de comprensión para que los investigadores de Machine Learning y ciencia política puedan entender a mayor profundidad la mecánica detrás de la creación del voto y popularice el uso del *social listening* para asuntos públicos en Bolivia, Colombia y en menor medida Latinoamérica.

2. Pregunta de investigación:

¿Cómo se comporta la capacidad predictiva de los modelos de Machine Learning aplicados a elecciones presidenciales en Latinoamérica adaptados a un contexto de alta dispersión de candidatos, series temporales cortas y limitaciones de información?

- Factible: Existen datos históricos detallados de los resultados de ambas elecciones

y encuestas constantes. Otros estudios han usado entre 20.000 y 60.000 publicaciones y los documentos con resultados electorales tienen alrededor de 16 millones de filas, lo que es una cantidad de datos que pueden ser procesados con la capacidad existente.

- Interesante y Novedosa: Sería el primer caso de uso de Machine Learning para elecciones con estas características.
- Ética: Se mantiene la como la transparencia en el uso de los datos, la protección de la privacidad de los votantes, y el uso responsable de los resultados
- Relevante: Los candidatos del país estarían profundamente interesados en el uso de los resultados para servicios de nowcasting

3. Marco conceptual

a. Antecedentes:

Por lo menos desde finales de los años 70s los politólogos tanto en los Estados Unidos como en Inglaterra (Stegmaier et al., 2023) han usado modelos predictivos para las elecciones presidenciales y/o legislativas de estos países. Estos empezaron siendo modelos sencillos basados en popularidad (Brown & Chappell, 1999; Sigelman, 1979; Whiteley, 1979). Con el desarrollo de modelos más complejos, y usando las herramientas econométricas a la mano, se desarrollaron estudios de modelos comparativos, paramétricos que usaban variables económicas como el PIB y el desempleo (Mughan, 1987; Sanders, 1991), pasando de modelos para entender la mecánica ex-post de una elección, a verdadera predicción ex-ante, con resultados incluso superiores a los de las encuestadoras de su tiempo.

Estos modelos se volvieron cada vez más avanzados y eficaces al momento de describir y predecir los resultados electorales, aun así, se volvieron especializados a los modelos bipartidistas de los Estados Unidos, Francia(Mongrain, 2022)) y en particular del Reino Unido con su sistema parlamentario (Clarke & Stewart, 1994). Estos modelos popularizados en los años 90s y 2000 beben de modelos paramétricos de series de tiempo como VAR y ARMA (Lewis-Beck et al., 2004; Norpoth, 2004) usados ampliamente en *forecasting* macroeconómico (Enders, 2009) lo que también implica una rigidez teórica y práctica en la aplicación de estos modelos.

Estos modelos han seguido avanzando en complejidad desde entonces, pero, por lo menos desde el año 2015 estos modelos paramétricos han enfrentado dificultades y resultados menos exactos. Este año fue decisivo en Reino Unido ya que ningún modelo bien establecido fue incapaz de predecir una mayoría conservadora en Reino Unido (Stegmaier et al., 2023) y solo un año después, los modelos predictivos fracasaron en predecir la victoria de Donald Trump en los Estados Unidos, del Brexit y la consecuente salida del Reino Unido de la Unión Europea (Philippou, 2021).

Esta crisis del sector obligó a los investigadores a salir de los modelos paramétricos y experimentar con nuevas tecnologías para la predicción electoral, en particular, el uso de redes sociales (Burnap et al., 2016) y de elecciones locales como proxy de elecciones nacionales (Prosser, 2016). Aunque desde antes de 2014 ya se habían hecho intentos de

utilizar redes sociales para realizar predicciones electorales (Anjaria & Guddeti, 2014), estas propuestas aumentaron después del 2015 y han sido cada vez más relevantes (Singh et al., 2020). También se han traspasado a otros contextos nacionales por fuera de los Estados Unidos y el Reino Unido, en particular en la India.

Desde el año 2010 se sabe que el número de tweets o publicaciones se puede considerar como una covariable directamente correlacionada con el porcentaje de participación de un candidato en el voto total (Tumasjan et al., 2010) y lo que es incluso más relevante, su capacidad predictiva es similar a una encuesta. Bajo estas premisas, el presente trabajo existe.

b. Marco teóricos:

- Long Short-Term Memory (LSTM): El modelo LSTM es una red neuronal recurrente (RNN) diseñada para superar las limitaciones de las RNN tradicionales, como la incapacidad de recordar dependencias a largo plazo. Los LSTM cuentan con celdas de memoria que controlan qué información se conserva, actualiza o descarta a través de tres compuertas principales: de entrada, de olvido y de salida. Esto los hace especialmente útiles para tareas secuenciales como la predicción basada en datos temporales o textuales, como menciones en redes sociales.
- Peephole Long Short-Term Memory (PLSTM): El modelo PLSTM es una variación de LSTM que permite que las compuertas accedan directamente al estado de la celda, lo que mejora su capacidad para manejar dependencias complejas. Esto es particularmente beneficioso en series temporales con relaciones no lineales, como los picos de menciones de candidatos en eventos específicos.
- Two-Stage Residual Long Short-Term Memory (TSRLSTM): El TSRLSTM es una arquitectura avanzada que utiliza una combinación de LSTM y capas residuales en dos etapas para manejar datos secuenciales con alta precisión. Las capas residuales minimizan el problema de gradientes desaparecidos y ayudan a capturar relaciones más profundas en los datos. Este modelo es efectivo en predicciones de secuencias largas con múltiples variables de entrada.
- Bidirectional Encoder Representations from Transformers (BERT): BERT es un modelo de lenguaje basado en transformers que procesa datos de texto en ambas direcciones (hacia adelante y hacia atrás), mejorando la comprensión del contexto. En el análisis electoral, se utiliza para tareas de clasificación de texto, análisis de sentimientos y extracción de temas relevantes de redes sociales.
- Linear Support Vector Classifier (LSVC): El LSVC es una variante de la Support Vector Machine (SVM) que utiliza un clasificador lineal para separar clases en el espacio de características. Es particularmente útil en escenarios donde las relaciones entre variables pueden representarse de manera lineal, como la clasificación de usuarios de redes sociales según su orientación política.
- Random Forest + Gradient Boosting Classifier + Voting Classifier: Esta combinación emplea múltiples algoritmos de ensamble para mejorar la precisión y robustez de las predicciones:
    1. Random Forest: Conjunto de árboles de decisión que genera múltiples clasificaciones y las combina mediante votación.

2. Gradient Boosting: Técnica iterativa que optimiza el desempeño de los clasificadores ajustando errores residuales.
3. Voting Classifier: Combina predicciones de múltiples modelos (como Random Forest y Gradient Boosting) para tomar una decisión final basada en el consenso.

- Parametric Models: Los modelos paramétricos como ARMA, VAR y regresión logística se basan en suposiciones estrictas sobre la distribución de los datos y las relaciones entre variables. Estos son útiles en contextos bien definidos pero limitados frente a la complejidad de los datos modernos.
- Decision Trees: Los árboles de decisión son algoritmos simples que dividen los datos en función de preguntas binarias (sí/no). Son rápidos y fáciles de interpretar, pero pueden sobre ajustarse si no se combinan con técnicas de ensamble como Random Forest.
- AdaBoost: Adaptive Boosting (AdaBoost) es un algoritmo de ensamble que combina múltiples clasificadores débiles para formar un clasificador fuerte, ponderando cada uno según su desempeño en las iteraciones previas.
- K-Nearest Neighbors (KNN): El algoritmo KNN clasifica datos basándose en la cercanía a los k vecinos más cercanos en el espacio de características. Es útil para problemas simples, pero no escala bien con datos de alta dimensionalidad.
- Natural Language Processing (NLP): NLP es un campo de la inteligencia artificial que permite a las máquinas entender, interpretar y generar lenguaje humano. En predicción electoral, NLP se utiliza para analizar sentimientos, temas y opiniones en redes sociales.
- Web Scraping: Web scraping es el proceso de extraer datos de sitios web de forma automatizada. Es fundamental para recolectar información en tiempo real de redes sociales y páginas de noticias relacionadas con eventos electorales.
- General Regression Neural Networks (GRNN): El GRNN es un modelo de redes neuronales diseñado para regresión continua. Es conocido por su rapidez en el entrenamiento y precisión en problemas con datos ruidosos o no lineales.
- Support Vector Machine (SVM): El SVM clasifica datos al encontrar un hiperplano óptimo que maximiza la separación entre clases. Es efectivo en problemas lineales y no lineales, con versiones como el kernel SVM para mayor flexibilidad.

c. Estado del arte:

El uso de **machine learning** para predecir resultados electorales ha ganado relevancia en la última década, especialmente a través del análisis de datos provenientes de redes sociales. En la mayoría de los casos estudiados, la red social *X* (antes llamada Twitter) ha sido la fuente predilecta de datos, aunque existen investigaciones que han explorado otras redes sociales como Facebook e Instagram, destacándose por su enfoque innovador en metodologías y modelos.

Estudios en Contextos Globales

En Estados Unidos, Pekar et al., (2022) investigaron cómo las intenciones de voto en redes sociales y las encuestas políticas se relacionaron durante las elecciones presidenciales de 2016, uno de los grandes casos de estudio de estos modelos. Este trabajo empleó *Natural Language Processing (NLP)*. Por su parte, Feng et al., (2023) combinaron algoritmos

avanzados como *Gradient Boost Trees* y *Multilayer Perceptrons* para predecir los resultados de las elecciones presidenciales, alcanzando una notable precisión del 96%. Asimismo, Khan et al., (2023) implementaron herramientas de análisis de localización como *LEPM* y *VADER*, logrando un 84% de precisión.

En India, los estudios de Gohil et al., (2023) para las elecciones regionales en Karnataka utilizaron modelos como *Random Forest* y *Gradient Boosting Classifier*, logrando una precisión del 85%. Singh et al., (2020), al analizar las elecciones legislativas en Punjab, aplicaron modelos más tradicionales como *Support Vector Machine (SVM)* y *Decision Trees*, obteniendo un 79% de precisión.

En Nigeria, Oyewola et al., (2023) optimizaron el análisis de sentimientos en las elecciones presidenciales mediante modelos avanzados de *Long Short-Term Memory (LSTM)* y sus variantes, aunque no reportaron precisión. En otro estudio, Olabanjo et al., (2023) integraron herramientas como *BERT* y *Linear Support Vector Classifiers (LSVC)* para predecir resultados electorales, logrando una precisión inferior al 80%.

Estudios en América Latina

En Latinoamérica, los estudios sobre predicción electoral han sido limitados, enfocados únicamente en elecciones presidenciales. Brito & Adeodato (2023) lideraron un estudio notable que incorporó innovaciones ausentes en trabajos previos:

1. **Uso de modelos comparativos de machine learning**: Implementaron *Multilayer Perceptrons (MLP)* y *General Regression Neural Networks (GRNN)*, diferenciándose de modelos más tradicionales como *Random Forest* o *Gradient Boosting*.
2. **Análisis de múltiples redes sociales**: Plantearon la metodología **SoMEN**, que unificó interacciones entre usuarios de Facebook, Instagram y *X*.

Limitaciones y Tendencias

En Chile, Rodríguez et al., (2018) exploraron el uso de *X* para predecir elecciones presidenciales, empleando modelos como *Decision Trees* y *AdaBoost*, con una precisión del 83%. Este caso resalta la importancia de combinar modelos tradicionales y avanzados para enfrentar limitaciones como sesgos en las fuentes de datos.

Por otro lado, aunque metodologías avanzadas como *BERT*, *LSTM* y *Multilayer Perceptrons* han mostrado gran potencial, su implementación no garantiza una alta precisión en todos los contextos. Esto refleja la necesidad de adaptar los modelos a las características de los datos y los sistemas electorales de cada región.

La predicción electoral mediante machine learning ha demostrado ser un campo prometedor, con aplicaciones que varían significativamente según el contexto geográfico y las herramientas empleadas. Si bien Estados Unidos e India lideran en términos de precisión y sofisticación de modelos, estudios en América Latina y África subrayan la necesidad de enfoques adaptativos e inclusivos. A medida que las redes sociales continúan siendo una fuente de datos clave, se espera que futuros estudios amplíen el alcance y la precisión de estas herramientas, integrando datos multisectoriales y modelos más robustos.

Nowcasting electoral

En ciencia política, *nowcasting* designa una predicción de "lo que pasaría si la elección se celebrara ahora", es decir, una actualización continua de la previsión basada en un modelo cuyos parámetros se mantienen fijos mientras varían las covariables observadas en tiempo real (LewisBeck & Tien, 2014).

La primera formulación aplicada a elecciones nacionales se consolidó con los modelos proxy: en Reino Unido, LewisBeck, Nadeau y Bélanger (2011) modelan el voto del oficialismo a partir de un indicador adelantado —aprobación del gobierno— medido con tres meses de antelación; y demuestran, además, que el *nowcast* ofrece señal informativa distinta (y con ventaja de anticipación) frente a las encuestas de intención de voto.

El modelo en dos pasos de LewisBeck et al. (2011) especifica (i) voto del gobierno como función de la aprobación *t3*; y (ii) aprobación como función de política y economía *t6*. En su serie 2005–2010, los *nowcasts* varían dentro de un rango relativamente acotado, en tanto las encuestas muestran oscilaciones casi tres veces mayores; además, ambas series son poco correlacionadas, lo que sugiere que capturan dimensiones distintas del ciclo electoral (p. ej., shocks políticos y patrón en U de popularidad gubernamental) (LewisBeck et al., 2011).

Posteriormente, LewisBeck y Tien (2014) extienden el enfoque de modelos proxy a Estados Unidos y formalizan el *nowcasting* como un dispositivo dinámico: emiten *nowcasts* mensuales para 2012, y con un indicador económico político (p. ej., *National Business Index*) pronostican con precisión la cuota de voto bipartidista del incumbente con seis meses de antelación; además, documentan ejemplos previos en Reino Unido y Francia (incluida la predicción de un "parlamento colgado" en 2010) (LewisBeck & Tien, 2014).

En eventos de decisión súbita con campaña comprimida, Tsakalidis, Aletras, Cristea y Liakata (2018) nowcastean la intención de voto de usuarios de Twitter en el referéndum griego (2015) durante ocho días, vía aprendizaje semisupervisado con múltiples kernels convolucionales que combinan señales temporales de texto y red social. Su esquema "en tiempo real" logra +20 % de Fscore sobre modelos solo textuales y muestra el valor de incorporar estructura de red y temporalidad (CIKM'18, pp. 367–376).

En una línea complementaria, Mavragani y Tsagarakis (2019) exploran búsquedas en Google para ahorapredecir referendos (Escocia 2014, Grecia 2015, Brexit 2016, entre otros). Su métrica de "*percentized hits*" se aproxima al resultado oficial e, incluso, supera la precisión de encuestas en ciertos casos (p. ej., Grecia 2015 y Reino Unido 2016; ver Figuras 1–3).

El estudio seminal de Tumasjan, Sprenger, Sandner y Welpe (2010) —basado en volumen de menciones y LIWC durante las legislativas alemanas de 2009— sostuvo que "el mero número de tuits" por partido refleja el resultado electoral y que la deliberación política es intensa en Twitter.
No obstante, una década de replicaciones y *surveys* sugiere que el enfoque Twitter solo (volumen ± sentimiento) no rinde mejor que el azar (tasas de acierto 50–63 %) y padece de problemas de muestreo, decisiones arbitrarias de recolección y cambios de plataforma (Brito, Silva Filho & Adeodato, 2024, *Government Information Quarterly*, 41, 101899). Su Tabla 2 propone direcciones: procesos repetibles, usar SM como parte de modelos estadísticos (no como sondeo), diversificar fuentes (múltiples redes y noSM como encuestas/economía), y si se usa *ML*, preferir regresión de voto sobre análisis de sentimiento (pp. 9–10).

Brito y Adeodato (2022) definen un conjunto de métricas de desempeño multiplataforma (Facebook, Twitter, Instagram) inspiradas en la teoría de la *mera exposición* de Zajonc. Con > 65 000 publicaciones de campañas presidenciales en Argentina 2019, Brasil 2018, Colombia 2018 y México 2018, hallan correlaciones altas entre desempeño (especialmente *engagement per-post*) y voto, mientras que el número de publicaciones presenta correlación nula o negativa (lo que desalienta proxies "volumétricos" ingenuos).

Con la intuición anterior, Brito y Adeodato (2020) entrenan redes neuronales por candidato usando datos de interacción de las cuentas oficiales (en lugar de menciones abiertas) combinados con encuestas como etiquetas. En Brasil 2018, el modelo supera a las encuestas en *vote share* en un escenario con muchos candidatos y pocas encuestas; en Estados Unidos 2016, resulta competitivo frente a un escenario de dos candidatos y muchas encuestas (IEEE IJCNN 2020, pp. 1–8). El enfoque es simple, replicable y más robusto a manipulación de volumen/bots al concentrarse en perfiles verificados de campaña.

Su propuesta se sistematiza en SoMEN (*Social Media framework for Election Nowcasting*), proceso y modelo con cinco pasos y una estrategia de ejecución SoMENDC que permite predicciones continuas durante la campaña. Aplicado a cuatro países (AR, BR, CO, MX), con 195 encuestas y ventana móvil de 300 días, SoMEN entrena ensambles de redes neuronales usando encuestas como *labels* y métricas de desempeño en SM como *features* (Brito & Adeodato, 2023, *Government Information Quarterly*, 40, 101782). La Tabla 1 resume los desafíos de la literatura (proceso, muestreo, modelado, rigor) y cómo el marco los aborda; por ejemplo, sustituye los barridos masivos de tuits por una recolección mucho menor ("miles de posts" de "< 12 candidatos"), sin necesidad de diccionarios/keywords, multiplataforma y con múltiples tamaños de ventana (lo que evita decisiones arbitrarias).

En la evaluación intermedia, los errores absolutos medios (MAE) de SoMEN respecto a encuestas suelen ser ≤ 3 p.p. y, en varios casos, inferiores al umbral histórico de 2,7 p.p. con el que la propia literatura de sondeos se compara; ver figuras de Brasil, Colombia y México (Brito & Adeodato, 2023). Aunque la varianza de encuestas cercana a la elección dificulta conclusiones "finales" tajantes, el marco demuestra viabilidad de *nowcasting* continuo con señales de SM + encuestas bajo restricciones realistas de datos y cómputo.

Síntesis y lecciones para una réplica en Colombia 2026 con APIs comerciales

1. **Factibilidad de datos con APIs comerciales.** Los enfoques basados en **perfiles oficiales** y métricas de desempeño (no en rastreo abierto de menciones) reducen costos de recolección y dependencia de *firehose*. SoMEN explicita que puede operar con **pocos miles de posts** y cruzar **múltiples plataformas** de forma estable (Brito & Adeodato, 2023).

2. **Estimación independiente de intención de voto.** El *nowcasting* con **SM + encuestas** como etiquetas permite emitir estimaciones **continuas** (SoMEN-DC), aprovechar la **dinámica** del ciclo y evitar sesgos de muestreos no representativos de Twitter-solo (Lewis-Beck et al., 2011; Brito et al., 2024).

3. **ML competitivo con encuestas.** Con **redes neuronales** por candidato e *inputs* de desempeño en SM, hay evidencia de resultados **competitivos** e incluso superiores respecto de encuestas en contextos multipartidistas (Brito & Adeodato, 2020; 2023).

4. Objetivo General

Aplicar un modelo de Machine Learning tipo GRNN y MLP para predecir los resultados de las Elecciones presidenciales en Colombia del año 2026, en condiciones de alta dispersión

electoral (más de 70 precandidatos) y limitaciones al acceso de la información de redes sociales

a. Objetivos Específicos

- **Diseñar y validar un pipeline de recolección de datos mediante web scraping y APIs comerciales** que permita construir un dataset representativo de la actividad en redes sociales (X, Instagram, Facebook y TikTok) durante los 200 días previos a las Elecciones presidenciales del 2026 en Colombia y 7 días antes en Bolivia.

- Construir el dataset base para el entrenamiento del modelo de predicción aplicado a las Elecciones presidenciales de Bolivia, Segunda vuelta, 2025.

- **Implementar y entrenar modelos de predicción basados en redes neuronales GRNN y MLP** utilizando las variables derivadas del comportamiento en redes sociales para estimar los resultados electorales de la Segunda vuelta presidencial en Bolivia realizada el 19 de octubre del 2025.

5. Metodología

La metodología utilizada en este proyecto sigue el estándar CRISP-DM (*Cross-Industry Standard Process for Data Mining*), asegurando un enfoque estructurado y replicable. A continuación, se describe cada fase y las actividades desarrolladas para alcanzar los objetivos específicos.

a. Comprensión del problema

El objetivo fundamental del “Sector” es el de predecir con mayor certeza, menor costo y más cerca del tiempo real, la intención de voto de los votantes en el contexto de una elección. El uso de redes sociales para la predicción de este fenómeno permite usar una fuente de datos de gran tamaño, que se actualiza en tiempo real y que, dependiendo del contexto, es una muestra representativa de la sociedad en su conjunto.

Las dos principales métricas de éxito para saber si el modelo utilizado cumple con el objetivo serán, por un lado, las variables de error del modelo (Mean Average Error) y la diferencia porcentual del modelo con los resultados de las elecciones de alcaldía.

Algunos de las limitaciones para conseguir este objetivo son las siguientes (Tabla 1):

Tabla 1: desafíos para el proceso de recolección de datos

Categoría	
Muestreo de información	**La cobertura de X (Twitter) en Latinoamérica no es lo suficientemente alta para ser una muestra significativa**
	X (Twitter) es una red social muy grande y 20.000 no es un número representativo

	El proceso de muestreo puede ser sesgado dentro de X (Twitter)
	X (Twitter) y otras redes sociales no tienen suficientes tweets relacionados a la escogencia de presidente
	Susceptibilidad a bots y manipulación por volumen
Modelado	**Falta de capacidad de computación a gran escala**
	Dificultad de comunicación de datos de distintas fuentes
	Uso de APIs comerciales con limitaciones de tiempo y uso
Rigor académico	**Falta de análisis estadístico profundo de los resultados y justificación para escoger una red social sobre otra**

En este caso podemos definir una situación de éxito en la que, en alguna de las elecciones estudiadas, el modelo iguale o supere la exactitud de las encuestas realizadas a menos de un mes de las elecciones y que la tendencia del *nowcasting* sea arbitrariamente similar a la del agregado de las encuestas.

En caso de que esto se cumpliera, habríamos creado un producto/servicio relevante, útil y rentable para las encuestadoras, asesores de campaña y candidatos. Al mismo tiempo podríamos extraer conclusiones relevantes sobre el proceso electoral en este año y avanzar la difusión de las herramientas de Machine Learning en Latinoamérica.

Aunque el inicio formal de las elecciones en Colombia es tres meses antes del día de las elecciones y hasta una semana antes de ese día según la legislación colombiana. La pre-campaña puede iniciar más de un año antes de los comicios, por esto tomamos una ventana de 200 días.

En una misma elección pueden presentarse decenas de candidatos, muchos de ellos con intenciones de voto muy bajas, por ejemplo. En las elecciones de 2023, en el municipio de La Florida, Valle del Cauca se presentaron diecinueve candidatos, de los cuales solo 4 tuvieron una votación de más del 5% (Registraduría nacional del estado civil, 2023).

En el estudio de Brito y Andeoato (2023), se eliminaron candidatos con una intención de voto de menos del 1%, en este caso, consideramos que ese límite debería ser del 3%.

b. Comprensión de los datos

El supuesto básico que justifica el hecho de usar redes sociales como fuente para el estudio de los fenómenos electorales es la idea de que existe una correlación directa entre la exposición de un candidato y su aprobación y participación en el porcentaje de votos en una elección (Oppenheimer et al., 1986). Todo esto por un proceso de condicionamiento clásico (Zajonc, 2001). Por lo tanto, usamos las interacciones de los ciudadanos con los candidatos como una variable proxy de su exposición al mismo. Usamos las interacciones en redes sociales para medir la atención que los ciudadanos les dan a un candidato. Dado que las

publicaciones con más interacciones son más publicitadas en las redes sociales, debería haber una correlación entre exposición del candidato y mayor intención de voto.

i. Recolección inicial de datos

- Se buscan extraer publicaciones públicas en X (Twitter), Instagram, Facebook y TikTok mediante técnicas de *web scraping* y acceso a sus respectivas APIs a través del servicio de Apify para usar web scrappers (https://apify.com/apidojo):
    - Se recolectarán datos durante un periodo de 200 días anteriores a las elecciones en el caso colombiano y 7 días en el caso boliviano, obteniendo textos, métricas de interacción (número de likes, comentarios y compartidos) y metadatos (fecha, hashtags, ubicación, etc.). Usando variables en la Tabla 2:
    - Estas interacciones se recaudan en los últimos diez minutos del domingo de cada semana en el caso colombiano y cada día en el caso boliviano, tomando solo aquellas publicaciones y sus interacciones que hayan sido realizadas en la semana anterior a través de un pipeline de datos.

Tabla 2: Variables a analizar en el conjunto de datos de redes sociales

1. Facebook

Variable	Descripción
FBPosts	Suma de publicaciones del candidato en el período.
FBLikes	Suma de “me gusta” recibidos en el período.
FBShares	Suma de veces compartido el contenido en el período.
FBComments	Suma de comentarios recibidos.
FBLikesPPost	Promedio de “me gusta” por publicación.
FBSharesPPost	Promedio de compartidos por publicación.
FBCommentsPPost	Promedio de comentarios por publicación.

2. Twitter (X)

Variable	Descripción
TTPosts	Suma de tuits en el período.
TTLikes	Suma de “me gusta” en los tuits.
TTRetweets	Suma de retuits recibidos.
TTLikesPPost	Promedio de “me gusta” por tuit.
TTRetweetsPPost	Promedio de retuits por tuit.

3. Instagram

Variable	Descripción
IGPosts	Suma de publicaciones en el período.
IGLikes	Suma de “me gusta” recibidos.

IGComments	Suma de comentarios recibidos.
IGLikesPPost	Promedio de “me gusta” por publicación.
IGCommentsPPost	Promedio de comentarios por publicación.

4. TikTok

Variable	Descripción
TTKPost	Número total de videos publicados por el candidato.
TTKLikes	Total de “me gusta” recibidos en los videos.
TTKComments	Total de comentarios recibidos.
TTKShares	Total de veces compartidos los videos.
TTKFavorites	Total de veces que los usuarios guardaron el video.
TTKLikesPost	Promedio de “me gusta” por video.
TTKCommentsPost	Promedio de comentarios por video.
TTKSharesPPost	Promedio de veces compartido por video.
TTKFavoritesPPost	Promedio de guardados por video.

- Se buscan extraer y procesar los resultados de encuestas mensuales de, por lo menos cinco consultoras reputadas registradas oficialmente en el Consejo Nacional Electoral cuyos resultados son libremente accesibles a través del enlace: https://www.cne.gov.co/encuesta2

ii. Descripción de los datos:

- Formato: JSON y CSV.
- Número de registros: Aproximadamente 2.000 publicaciones en el caso boliviano.

c. Exploración y visualización:

Se realizarán análisis iniciales para comprender la distribución de palabras, frecuencias de publicación y patrones temporales. Herramientas como Python (*pandas*, *matplotlib*, *seaborn*) facilitarán esta tarea. Para visualizar usaremos gráficas para series de tiempo junto a nubes de palabras para el análisis de sentimiento y redes de puntos de relación entre cuentas.

Los conjuntos de datos descargados necesitan un nivel de limpieza muy bajo, una vez estén limpios, se establecen las ventanas de tiempo ajustables con un intervalo de 28 días alrededor de cada encuesta. Se toma una ventana de 28 días de forma arbitraria porque no se encuentra relación entre esta ventana y la capacidad de predicción (Brito y Andeoato, 2023). Para lidiar con el escaso número de encuestas, usamos un Principal Component Analysis.

d. Evaluación de calidad:

Para limpiar publicaciones de redes sociales y garantizar que los datos sean relevantes para predecir resultados electorales, se deben realizar los siguientes procesos:

Detección y eliminación de publicaciones irrelevantes:

- Análisis de longitud de texto: Filtrar publicaciones excesivamente cortas o largas que no aporten contenido útil.
- Frecuencia de palabras clave: Verificar que las publicaciones contengan términos relacionados con el contexto electoral, descartando aquellas que no lo hagan.
- Filtros de idioma: Excluir publicaciones en idiomas distintos al idioma objetivo del análisis.

Identificación de valores atípicos:

- Detectar y eliminar publicaciones con características anómalas, como un uso desproporcionado de emojis o caracteres especiales, que puedan ser ruido en lugar de contenido relevante.

Manejo de valores faltantes:

- Revisar campos clave como ubicación geográfica y etiquetas de usuario.
- Descartar publicaciones con demasiados valores faltantes o imputarlos cuando sea posible sin comprometer la calidad del análisis.

Validación final de la relevancia:

- Implementar reglas adicionales basadas en criterios específicos del contexto electoral, como excluir cuentas spam o publicaciones de bots. Identificables porque han sido creados hace pocas horas de la publicación.

Este enfoque asegura que los datos utilizados sean relevantes y representativos para modelar y predecir tendencias electorales.

e. Comparación con encuestas ya realizadas: en la obra de Brito y Andeoato (2023) se escogieron, para las elecciones presidenciales en Colombia del 2026 las siguientes consultoras productoras de encuestas, con el objetivo de mantener la mayor similitud metodológica, eliminando aquellas empresas que no están autorizadas para realizar dichas encuestas:

- Centro Nacional de Consultoría S.A. (Aprobada)
- Cifras y Conceptos S.A.S. (Aprobada)
- Datexco Company S.A.S. (No aprobada)
- Guarumo S.A.S. (Aprobada)
- Invamer S.A.S. (No aprobada)
- YanHaas S.A. (Aprobada)

Para el caso boliviano se usan las encuestadoras más recientes a la fecha de inicio del levantamiento de la información:

- Ipsos Ciesmori (6-9 de octubre del 2025)

6. **Impacto esperado:**

Aunque los modelos de Machine Learning, como GRNN y MLP, han mostrado resultados prometedores en la predicción de elecciones presidenciales en Colombia, incluso superando en algunos casos a las encuestadoras tradicionales (Brito & Adeodato, 2023), su aplicación a estas elecciones presidenciales representa un desafío adicional. Esto se debe a las diferencias inherentes en las dinámicas electorales, donde factores como la fragmentación del voto, la influencia de liderazgos regionales y la diversidad de contextos socioeconómicos pueden afectar la capacidad predictiva de los modelos. Las modificaciones necesarias para adaptar estas herramientas al entorno local podrían reducir su precisión inicial.

7. Resultados preliminares

   a. Objetivo 1:

"Diseñar y validar un pipeline de recolección de datos mediante web scraping y APIs comerciales que permita construir un dataset representativo de la actividad en redes sociales (X, Instagram, Facebook y TikTok) durante los 200 días previos a las Elecciones presidenciales del 2026 en Colombia y 7 días antes en Bolivia."

Para realizar este pipeline de tratamiento de datos de redes sociales, se usaron dos tipos de herramientas, la primera es el uso de APIs de pago a través de la plataforma Apify.com. A través de la cual se pueden contratar los servicios de distintos *Actores.* Estos, a partir de un comando en JSON, puede extraer datos de cuentas o links particulares de redes sociales u otras páginas. Estos actores tienen un costo por uso, este puede ser una suscripción mensual o un cobro marginal por resultado, estos fueron usados para las redes sociales de Facebook, Instagram y TikTok. Existen varios actores para una misma red social y varios para aspectos particulares como lo pueden ser perfiles, publicaciones o elementos multimedia como videos o imágenes.

Estos actores pueden estar desarrollados por la misma plataforma de Apify o por usuarios que desarrollan y alquilan sus actores. Estos últimos pueden ser mantenidos por sus propios usuarios o por la comunidad en su conjunto. Para este ejercicio se usaron los siguientes actores:

i. **Instagram Scrapper:** herramienta desarrollada por la plataforma Apify, es solo una del conjunto de herramientas de la plataforma para Instagram, esta permite extraer publicaciones, comentarios, detalles del perfil. Menciones y reels. En este ejercicio se usó la modalidad de búsqueda por publicaciones. Su costo, al 13 de octubre del 2025 es de 2.3 dólares estadounidenses por cada mil resultados. El JSON de indicaciones usado fue el siguiente es el siguiente:

Figura 1: JSON de indicaciones para Instagram

```
{
```

```
    "addParentData": false,
    "directUrls": [
        "{Link del candidato}/"
    ],
    "enhanceUserSearchWithFacebookPage": false,
    "isUserReelFeedURL": false,
    "isUserTaggedFeedURL": false,
    "onlyPostsNewerThan": "{Fecha máxima}",
    "resultsLimit": 100,
    "resultsType": "posts",
    "searchLimit": 1,
    "searchType": "hashtag"
}
```

ii. **Facebook Scrapper:** herramienta desarrollada por la plataforma Apify, es solo una del conjunto de herramientas de la plataforma para Facebook, esta permite extraer publicaciones exclusivamente. Permite definir escalas de tiempo de las publicaciones a diferencia de Instagram, por lo cual se definió para cada fin de semana solo escoger las publicaciones de la semana que termina. Su costo es de 0.01 dólares estadounidenses por resultado. El JSON de indicaciones usado fue el siguiente es el siguiente:

Figura 2: JSON de indicaciones para Facebook

```
{
    "captionText": false,
    "onlyPostsNewerThan": "{Fecha de inicio}",
    "onlyPostsOlderThan": "{Fecha de fin}",
    "resultsLimit": 100,
    "startUrls": [
        {
            "url": “{Link del perfil del candidato}”,
            "method": "GET"
        }
    ]
}
```

iii. **TikTok Profile Scrapper:** herramienta desarrollada por el usuario Clockworks y mantenido por la plataforma Apify, es solo una del conjunto de herramientas de la plataforma para Tiktok, esta permite extraer publicaciones exclusivamente, pero, es una herramienta lo suficientemente flexible para extraer datos de videos y de reposts. No permite definir escalas de tiempo de las publicaciones a diferencia de Facebook, solo una fecha de inicio, por lo cual se definió para cada fin de semana solo escoger las publicaciones de la semana que termina. Su costo es de 0.04 dólares estadounidenses por resultado. El JSON de indicaciones usado fue el siguiente es el siguiente:

Figura 3: JSON de indicaciones para X

```
{
   "excludePinnedPosts": false,
   "oldestPostDateUnified": "{Fecha de inicio}",
   "profileScrapeSections": [
      "videos"
   ],
   "profileSorting": "latest",
   "profiles": [
      "{nombre de usuario}"
   ],
   "resultsPerPage": 100,
   "shouldDownloadAvatars": false,
   "shouldDownloadCovers": false,
   "shouldDownloadSlideshowImages": false,
   "shouldDownloadSubtitles": false,
   "shouldDownloadVideos": false
}
```

iv. **TwitterApi:** a diferencia de las otras redes sociales, en el caso de X se usó un servicio específico, no parte de Apify, el cual, a través de un API Key, permite crear código en Python que permite extraer los datos de publicaciones en la página. El código usado está en el Anexo 1. Este tiene un costo de, alrededor de 0.04 dólares estadounidenses por resultado. Twitter API funciona con una compra de tokens por el cual 1 dólar es igual a 100.000 tokens.

Los primeros tres servicios usan un orquestador para ejecutarse todas las semanas, en los últimos diez minutos de la semana. En el caso de X, se ejecuta el código del Anexo 1 en ese mismo momento en cada día. En el caso boliviano, se realiza el mismo ejercicio, pero en los últimos diez minutos de cada día, sea de forma manual en el caso de X, o a través del orquestador en las demás redes sociales.

El orquestador utilizado es la plataforma make.com, que permite orquestar todo tipo de servicios, incluído los que Inteligencia artificial (LLM como ChatGPT, creación de video o texto, etc.) Este servicio tiene un costo mensual de 10,59 dólares estadounidenses mensuales, equivalente a 10.000 créditos donde un crédito equivale a un llamado o acción.

Este orquestador realiza la ejecución programada del actor en Apify, tomando el nombre, links de redes sociales y fechas de guía de un documento de Google Sheets, después descarga el JSON resultante, lo transforma en un CSV y lo concatena dentro del mismo documento de Google Sheets.

Figura 4: Ejemplo de pipeline para Facebook

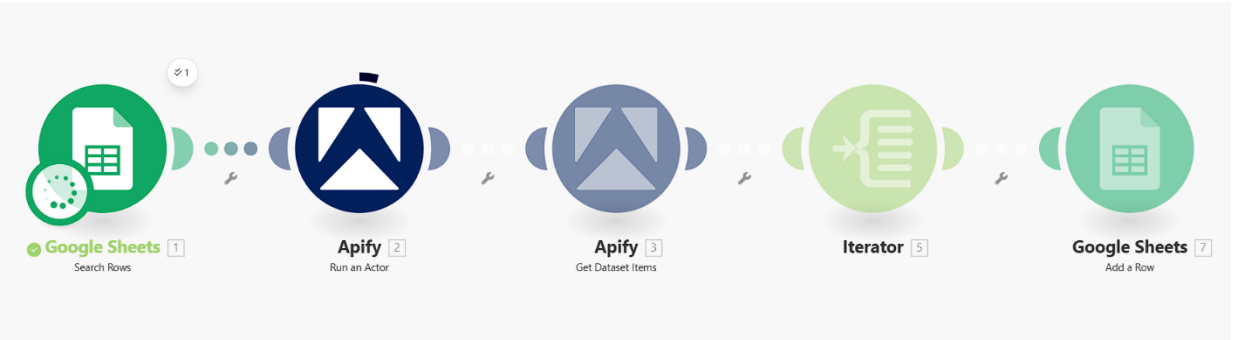

La estructura de los distintos pipelines se une a través de dos documentos de Google Sheets que mantienen la ejecución constante de los scripts todos los días.

Figura 5: Estructura de conexión de los distintos pipelines

b. Objetivo 2:

"Construir el dataset base para el entrenamiento del modelo de predicción aplicado a las Elecciones presidenciales de Bolivia, Segunda vuelta, 2025"

Siguiendo con la metodología SOMEN-DC, desarrollada por Brito y Andeoato (2022). Se adaptó el proceso de entendimiento de las elecciones, levantamiento de datos y análisis a un contexto de tiempo muy limitado, de tan solo siete días. Esto con el objetivo de probar la metodología con datos conseguidos de forma abierta y comercial.

1. **Election Understanding (comprensión del evento)**

Contexto nacional

Bolivia es considerado por organismos internacionales como un estado con serias deficiencias en su sistema democrático (Idea Institute, 2025). Principalmente, por el mantenimiento de la figura de Evo Morales en la presidencia de forma continua desde el 2006 hasta el 2019 y de su partido, el MAS (Movimiento al Socialismo), de forma casi ininterrumpida desde entonces. Esto debido a cambios en la Constitución, interpretaciones favorables a su figura por parte del Tribunal Constitucional de Bolivia y eventualmente a través de intervenciones e irregularidades en las elecciones realizadas en el año 2019 que terminarían en un motín policial, la renuncia de Evo Morales y el ascenso del breve gobierno de la oposición de parte de Jeanine Añez y la presidencia del ex-vicepresidente de Evo Morales, Luis Arce que se mantiene hasta las presentes elecciones.

Se definió como objeto de estudio la segunda vuelta presidencial en Bolivia (19/10/2025), con dos candidatos: Rodrigo Paz Pereira (Partido Demócrata Cristiano) y Jorge "Tuto" Quiroga (Alianza Libre). Es un balotaje atípico por la ausencia de un candidato del MAS tras la fractura interna del partido de gobierno.

Levantamiento de información

Resultado del proceso de web scraping realizado diariamente entre el 11 y el 18 de octubre de 2025, sobre las cuentas oficiales de los dos candidatos en Twitter (X), Facebook, Instagram y TikTok. Cada ejecución del script se efectuó a las 23:50 (hora local de La Paz), consolidando todas las publicaciones e interacciones generadas durante el día. Cada observación cuenta con un timestamp (hora, minuto, segundo), y el análisis posterior confirmó que todas las descargas se completaron en menos de 15 minutos, garantizando la homogeneidad temporal diaria del muestreo.

Datos de referencia (etiquetas o labels):

Encuesta de intención de voto (IPSOS Ciesmori): realizada entre el 6 y 9 de octubre y publicada el 12 de octubre de 2025 por el medio UNITEL.

- Muestra: 2.500 personas, distribuidas en 111 localidades (urbanas y rurales, incluyendo las 9 capitales departamentales y El Alto). Margen de error: ±2,2% con 95% de confianza.
- Resultado electoral oficial: publicado la noche del 19 de octubre de 2025 por el Tribunal Supremo Electoral y replicado por Reuters, con 54,53% para Rodrigo Paz Pereira (PDC) y 45,47% para Jorge "Tuto" Quiroga (Libre).

Estas dos observaciones, la encuesta (pre-electoral) y el resultado (postelectoral), se emplean como valores de calibración y validación, respectivamente, de los modelos.

Después de realizar este cálculo, este fue el resultado (Ver anexo 1.)

Descripción formal del modelo

Siguiendo el marco SoMEN (Social Media framework for Election Nowcasting), el problema se modela como una regresión supervisada multivariada, donde las interacciones sociales agregadas sirven como predictores (features) y los porcentajes de voto sirven como variable

dependiente (objetivo).

Siendo:

$$x_{i,t} = (x_{1,t}, x_{2,t}, \dots, x_{n,t})$$

El vector de métricas sociales del candidato i en el día t, con n variables correspondientes a los indicadores descritos arriba.

$$y_t = f_\theta(x_t)$$

- $\hat{y} \in R^{2x1}$ representa el vector de logits o proporciones estimadas de voto para los dos candidatos (Paz y Quiroga),
- $f_\theta(\cdot)$ es una red neuronal entrenada con parámetros θ.

Dado que el sistema solo tiene **dos salidas**, el vector se normaliza como:

$$\widehat{y_{1,t}} + \widehat{y_{2,t}} = 1$$

y puede interpretarse directamente como el porcentaje de votos válidos proyectado para cada candidato.

Modelos implementados

Conforme a la metodología de Brito y Adeodato, se implementaron tres modelos comparativos:

- Regresión lineal simple (baseline):
  Modelo de referencia que estima la relación directa entre las variables de desempeño en redes sociales y los porcentajes de voto.
  $$y^t = \beta_0 + \beta^T x_t + \varepsilon_t$$
- Multilayer Perceptron – Backpropagation (MLP-BP):
  Se configuró un perceptrón multicapa con:
  - Una capa oculta con 3 neuronas (para evitar sobreajuste),
  - Activación logística $\sigma(z) = 1/(1 + e^{-z})$
  - Solver L-BFGS, adecuado para muestras pequeñas,
  - Tasa de aprendizaje constante y α=0.05\alpha=0.05α=0.05 (rápida convergencia),
  - Comité de 5 redes con semillas aleatorias distintas; la salida final es el promedio:
  $$\widehat{y_t^{MLP}} = \frac{1}{5}\sum_{k=1}^{5} f_{\theta_k}^{(MLP)}\, x_t$$
- General Regression Neural Network (GRNN):
  Red de tipo probabilístico basada en estimación de densidad kernel, apropiada para muestras pequeñas.
  La función de salida es:

$$y_t^{\widehat{(GRNN)}} = \frac{\sum_{i=1}^{N} y_i \exp\left[-\frac{(x_t - x_i)^2}{2\sigma^2}\right]}{\sum_{i=1}^{N} \exp\left[-\frac{(x_t - x_i)^2}{2\sigma^2}\right]}$$

donde σ es el parámetro de suavizamiento (*smoothing factor*) determinado mediante grid search en el rango [0.1,4.0] con incrementos de 0.20.

Entrenamiento

El conjunto de entrenamiento se construyó con los **ocho días de observación (11–18 de octubre)**. Cada vector diario $\mathbf{x}_t$agrupa las interacciones del día en las cuatro plataformas, sin aplicar ventanas acumuladas ($w = 1$), debido a la brevedad del periodo y la homogeneidad temporal de la captura. El valor de calibración se fijó con la encuesta **IPSOS (12/10)**:

$$\hat{y}_{Paz,12/10} = 0.365, \hat{y}_{Quiroga,12/10} = 0.449$$

Los pesos iniciales se ajustaron para cumplir esa condición de escala.

Evaluación

La predicción final ($t = 18/10$) se comparó con el resultado oficial ($t = 19/10$).
Se utilizaron tres métricas de error, siguiendo a Brito y Adeodato:

- **MAE (Mosteller 3):**
  $MAE = \frac{1}{n}\sum_i \quad | \hat{y}_i - y_i |$

- **RMSE:**

$$RMSE = \sqrt{\frac{1}{n}\sum_i \quad (\hat{y}_i - y_i)^2}$$

- **AEOM (Mosteller 5):**

$$AEOM = | (\hat{y}_{Paz} - \hat{y}_{Quiroga}) - (y_{Paz} - y_{Quiroga}) |$$

Valores de $MAE < 2{,}7\%$se consideran dentro del umbral histórico de error de encuestas (Jennings & Wlezien, 2018).

Resultados:

1. Extracción diaria (23:50): consolidar posts e interacciones.

En total, durante la última semana de campaña los candidatos publicaron 416 publicaciones en Facebook, 589 publicaciones en Instagram, 153 videos cortos en TikTok y tan solo 15 publicaciones en X. Esto contrasta fuertemente con los miles de publicaciones de ejercicios

más amplios, aún así, en muy poco tiempo fue posible conseguir un conjunto de datos relevante que muestra más de 416.000 interacciones en Twitter, 3´386.000 en Facebook, 6´105.000 en Instagram y 1´996.000 en TikTok.

2. Cálculo de variables agregadas y normalización por post.

Una vez descargadas todas las publicaciones de las cuatro plataformas (Twitter, Facebook, Instagram y TikTok) y consolidadas en el dataset diario, se procede a transformar las observaciones individuales en variables comparables entre candidatos y redes. El objetivo de este paso es obtener una representación homogénea que capture tanto el volumen de actividad como la intensidad media de interacción, reduciendo el sesgo por diferencias en frecuencia de publicación.

Sea $p_{i,r,t}$el conjunto de publicaciones realizadas por el candidato $i$en la red $r$durante el día t. Cada publicación $k \in p_{i,r,t}$contiene métricas de interacción como “me gusta”, comentarios, compartidos, vistas o guardados, dependiendo de la red.

Para cada combinación (i, r, t)se calculan los totales diarios:

$$L_{i,r,t} = \sum_{k \in p_{i,r,t}} \text{likes}_k,$$
$$C_{i,r,t} = \sum_{k \in p_{i,r,t}} \text{comments}_k,$$
$$S_{i,r,t} = \sum_{k \in p_{i,r,t}} \text{shares}_k,$$
$$V_{i,r,t} = \sum_{k \in p_{i,r,t}} \text{views}_k,$$
$$F_{i,r,t} = \sum_{k \in p_{i,r,t}} \text{favorites}_k,$$

donde las métricas inexistentes en una red (por ejemplo, *views* o *favorites* en Twitter) se tratan como cero.

El número de publicaciones se define como $N_{i,r,t} = | p_{i,r,t} |$.

Normalización por publicación

El volumen total de interacciones puede verse afectado por el número de publicaciones diarias.
Para aislar la **intensidad de interacción por contenido**, se calcula el promedio por publicación:

$$\bar{L}_{i,r,t} = \frac{L_{i,r,t}}{N_{i,r,t}}, \bar{C}_{i,r,t} = \frac{C_{i,r,t}}{N_{i,r,t}},$$
$$\bar{S}_{i,r,t} = \frac{S_{i,r,t}}{N_{i,r,t}}, \bar{V}_{i,r,t} = \frac{V_{i,r,t}}{N_{i,r,t}}, \bar{F}_{i,r,t} = \frac{F_{i,r,t}}{N_{i,r,t}}.$$

Estas medias reflejan el *engagement rate* o **tasa de respuesta promedio por publicación**, componente esencial de la teoría de exposición de Zajonc (1968), sobre la cual se fundamenta SoMEN.

Definición de variables por red social

El conjunto de métricas empleadas en el modelo sigue la taxonomía de Brito y Adeodato (2023), extendida al caso de TikTok. Cada red aporta un subconjunto específico de variables, agrupadas en **totales** y **promedios por publicación.** En total se obtienen 29 variables independientes (7 de Facebook, 5 de Twitter, 5 de Instagram y 12 de TikTok).

Construcción del vector de características

Para cada candidato i y día t, se construye el vector:

$$\mathbf{x}_{i,t} = [L_{i,r,t}, C_{i,r,t}, S_{i,r,t}, V_{i,r,t}, F_{i,r,t}, \bar{L}_{i,r,t}, \bar{C}_{i,r,t}, \bar{S}_{i,r,t}, \bar{V}_{i,r,t}, \bar{F}_{i,r,t}]_{r\in\{FB,TT,IG,TTK\}}$$

que consolida todas las métricas absolutas y relativas del día. Cada $\mathbf{x}_{i,t}$corresponde a una fila del *dataset* final de entrenamiento, con dimensión $n = 29$.

Estandarización intra-plataforma

Dado que los valores absolutos difieren drásticamente entre redes (por ejemplo, las *views* en TikTok pueden ser órdenes de magnitud mayores que los *likes* en Twitter), se aplica una **estandarización z-score** dentro de cada plataforma:

$$z_{i,r,t}^{(m)} = \frac{x_{i,r,t}^{(m)} - \mu_r^{(m)}}{\sigma_r^{(m)}}$$

donde $\mu_r^{(m)}$y $\sigma_r^{(m)}$son la media y desviación estándar de la métrica $m$en la red $r$durante el período 11–18 de octubre.
Esto asegura que cada métrica aporte información comparable y que las diferencias en escala no dominen el proceso de aprendizaje del modelo.

- Estandarización (z-score) por red social.
- Integración por candidato-día en una matriz 8×n.
- Entrenamiento de MLP y GRNN sobre esa matriz (etiqueta 12/10).
- Generación de predicciones diarias (11–18/10).
- Evaluación ex post comparando el valor del 18/10 con el resultado oficial (19/10).

Referencias bibliográficas:

(Anjaria & Guddeti, 2014; Cerón, 2024; Feng et al., 2023; Gohil et al., 2023; Rodríguez

et al., 2018; Sharma & Moh, 2016; Zuloaga-Rotta et al., 2024)

https://doi.org/10.3390/computation12030038

Anjaria, M., & Guddeti, R. M. R. (2014). *Influence factor based opinion mining of Twitter data using supervised learning*. 2014 6th International Conference on Communication Systems and Networks, COMSNETS 2014. Scopus. https://doi.org/10.1109/COMSNETS.2014.6734907

Barberá, P. (2020). Social media, echo chambers, and political polarization. En *Social Media and Democracy: The State of the Field, Prospects for Reform* (pp. 34-55). Scopus. https://doi.org/10.1017/9781108890960.004

Brito, K., & Adeodato, P. J. L. (2020). Predicting Brazilian and U.S. Elections with Machine Learning and Social Media Data. En 2020 International Joint Conference on Neural Networks (IJCNN) (pp. 1–8). Glasgow, United Kingdom: IEEE.

Brito, K., & Adeodato, P. J. L. (2022). Measuring the performances of politicians on social media and the correlation with major Latin American election results. *Government Information Quarterly*, *39*(4), 101745. https://doi.org/10.1016/j.giq.2022.101745

Brito, K., & Adeodato, P. J. L. (2023). Machine learning for predicting elections in Latin America based on social media engagement and polls. *Government Information Quarterly*, *40*(1), 101782. https://doi.org/10.1016/j.giq.2022.101782

Brito, K., Silva Filho, R. L. C., & Adeodato, P. J. L. (2024). Stop trying to predict elections only with Twitter—There are other data sources and technical issues to be improved. Government Information Quarterly, 41, 101899. https://doi.org/10.1016/j.giq.2023.101899

Brown, L. B., & Chappell, H. W. (1999). Forecasting presidential elections using history and polls. *International Journal of Forecasting*, *15*(2), 127-135. https://doi.org/10.1016/S0169-2070(98)00059-4

Burnap, P., Gibson, R., Sloan, L., Southern, R., & Williams, M. (2016). 140 characters to

victory?: Using Twitter to predict the UK 2015 General Election. *Electoral Studies*, *41*, 230-233. Scopus. https://doi.org/10.1016/j.electstud.2015.11.017

Cerón, R. Q. (2024, abril 10). *Proporción de personas de derecha en Colombia subió 6 puntos porcentuales en dos años*. El Tiempo.

https://www.eltiempo.com/datos/partidos-politicos-en-colombia-tienen-la-peor-credibilidad-revela-estudio-del-dane-3332314

Clarke, H. D., & Stewart, M. C. (1994). Economic evaluations and election outcomes: An analysis of alternative forecasting models. *British Elections and Parties Yearbook*. https://doi.org/10.1080/13689889408412942

Diamond, L. (2021). Democratic regression in comparative perspective: Scope, methods, and causes. *Democratization*, *28*(1), 22-42. Scopus. https://doi.org/10.1080/13510347.2020.1807517

Dickel, V., & Evolvi, G. (2023). “Victims of feminism”: Exploring networked misogyny and #MeToo in the manosphere. *Feminist Media Studies*, *23*(4), 1392-1408. Scopus. https://doi.org/10.1080/14680777.2022.2029925

Eady, G., Nagler, J., Guess, A., Zilinsky, J., & Tucker, J. A. (2019). How Many People Live in Political Bubbles on Social Media? Evidence From Linked Survey and Twitter Data. *SAGE Open*, *9*(1). Scopus. https://doi.org/10.1177/2158244019832705

Enders, W. (2009). *Applied Econometric Times Series*.

Feng, G., Chen, K., Cai, H., & Li, Z. (2023). *A Hybrid Method of Sentiment Analysis and Machine Learning Algorithm for the U.S. Presidential Election Forecasting*. 1495-1500. Scopus. https://doi.org/10.1109/BigData59044.2023.10386950

Gohil, R., Deepa, S., Vinay, M., & Jayapriya, J. (2023). *Election Forecasting with Machine Learning and Sentiment Analysis: Karnataka 2023*. IEEE 1st International Conference on Ambient Intelligence, Knowledge Informatics and Industrial Electronics, AIKIIE 2023. Scopus. https://doi.org/10.1109/AIKIIE60097.2023.10390333

Idea – Global State of Democracy initiative. (2025). https://www.idea.int/democracytracker/country/bolivia

Kennedy, C., Blumenthal, M., Clement, S., Clinton, J. D., Durand, C., Franklin, C., McGeeney, K., Miringoff, L., Olson, K., Rivers, D., Saad, L., Witt, G. E., & Wlezien, C. (2018). An Evaluation of the 2016 Election Polls in the United States. *Public Opinion Quarterly*, *82*(1), 1-33. Scopus. https://doi.org/10.1093/poq/nfx047

Khan, A. (2023). From Social Media to Ballot Box: Leveraging Location-Aware Sentiment

Analysis for Election Predictions. *Computers, Materials and Continua*, *77*(3), 3037-3055. https://doi.org/10.32604/cmc.2023.044403

Lewis-Beck, M. S., Nadeau, R., & Bélanger, E. (2004). General election forecasts in the United Kingdom: A political economy model. *Electoral Studies*, *23*(2), 279-290. https://doi.org/10.1016/S0261-3794(02)00071-9

Lewis-Beck, M. S., Nadeau, R., & Bélanger, É. (2011). Nowcasting v. polling: The 2010 UK election trials. Electoral Studies, 30(2), 284–287. https://doi.org/10.1016/j.electstud.2010.09.013

Lewis-Beck, M. S., & Tien, C. (2014). Proxy models and nowcasting: U.S. presidential elections in the future. Presidential Studies Quarterly, 44(3), 506–521.

Marcks, H., & Pawelz, J. (2022). From Myths of Victimhood to Fantasies of Violence: How Far-Right Narratives of Imperilment Work. *Terrorism and Political Violence*, *34*(7), 1415-1432. Scopus. https://doi.org/10.1080/09546553.2020.1788544

Mavragani, A., & Tsagarakis, K. P. (2019). Predicting referendum results in the Big Data era. Journal of Big Data, 6, 3. https://doi.org/10.1186/s40537-018-0166-z

Mongrain, P. (2022). Predicting in an (increasingly) unpredictable system? Forty years of election forecasting in France. *French Politics*, *20*(2), 210-225. https://doi.org/10.1057/s41253-022-00171-3

Mughan, A. (1987). General election forecasting in Britain: A comparison of three simple models. *Electoral Studies*, *6*(3), 195-207. https://doi.org/10.1016/0261-3794(87)90031-X

Norpoth, H. (2004). Forecasting British elections: A dynamic perspective. *Electoral Studies*, *23*(2), 297-305. https://doi.org/10.1016/S0261-3794(02)00070-7

Olabanjo, O., Wusu, A., Afisi, O., Asokere, M., Padonu, R., Olabanjo, O., Ojo, O., Folorunso, O., Aribisala, B., & Mazzara, M. (2023). From Twitter to Aso-Rock: A sentiment analysis framework for understanding Nigeria 2023 presidential election. *Heliyon*, *9*(5), e16085. https://doi.org/10.1016/j.heliyon.2023.e16085

Oppenheimer, B. I., Stimson, J. A., & Waterman, R. W. (1986). Interpreting U. S. Congressional Elections: The Exposure Thesis. *Legislative Studies Quarterly*, *11*(2), 227-247. https://doi.org/10.2307/439877

Oyewola, D. O., Oladimeji, L. A., Julius, S. O., Kachalla, L. B., & Dada, E. G. (2023). Optimizing sentiment analysis of Nigerian 2023 presidential election using two-stage residual long short term memory. *Heliyon*, *9*(4), e14836. https://doi.org/10.1016/j.heliyon.2023.e14836

Pachón Soto, D., Villar Roncancio, J. D., & Gómez Arévalo, M. A. (2024). Autoritarismo

regional: Análisis de la violencia contra servidores públicos y del reclutamiento forzado en el sur colombiano. *Historia Regional*, *51*, 7.

Pekar, V., Najafi, H., Binner, J. M., Swanson, R., Rickard, C., & Fry, J. (2022). Voting intentions on social media and political opinion polls. *Government Information Quarterly*, *39*(4), 101658. https://doi.org/10.1016/j.giq.2021.101658

Philippou, A. N. (2021). The Case of Four US Presidential Elections, Brexit, and Two India General Elections*. *Asian Journal of Statistical Sciences*, *1*(2), 65-74. Scopus.

Prosser, C. (2016). Do local elections predict the outcome of the next general election? Forecasting British general elections from local election national vote share estimates. *Electoral Studies*, *41*, 274-278. https://doi.org/10.1016/j.electstud.2015.11.008

Registraduría nacional del estado civil. (2023). *Registraduría Nacional del Estado Civil—Observatorio*. https://www.registraduria.gov.co

Rodríguez, S., Allende-Cid, H., Palma, W., Alfaro, R., Gonzalez, C., Elortegui, C., & Santander, P. (2018). Forecasting the Chilean electoral year: Using twitter to predict the presidential elections of 2017. *Lecture Notes in Computer Science (including subseries Lecture Notes in Artificial Intelligence and Lecture Notes in Bioinformatics)*, *10914 LNCS*, 298-314. Scopus. https://doi.org/10.1007/978-3-319-91485-5_23

Rovira Kaltwasser, C., & Van Hauwaert, S. M. (2020). The populist citizen: Empirical evidence from Europe and Latin America. *European Political Science Review*, *12*(1), 1-18. Scopus. https://doi.org/10.1017/S1755773919000262

Sanders, D. (1991). Government Popularity and the next General Election. *The Political Quarterly*, *62*(2), 235-261. Scopus. https://doi.org/10.1111/j.1467-923X.1991.tb00856.x

Sharma, P., & Moh, T.-S. (2016). *Prediction of Indian election using sentiment analysis on Hindi Twitter*. 1966-1971. Scopus. https://doi.org/10.1109/BigData.2016.7840818

Sigelman, L. (1979). Presidential Popularity and Presidential Elections. *Public Opinion Quarterly*, *43*(4), 532-534. https://doi.org/10.1086/268549

Singh, P., Dwivedi, Y. K., Kahlon, K. S., Pathania, A., & Sawhney, R. S. (2020). Can twitter analytics predict election outcome? An insight from 2017 Punjab assembly elections. *Government Information Quarterly*, *37*(2). Scopus. https://doi.org/10.1016/j.giq.2019.101444

Skoric, M. M., Liu, J., & Jaidka, K. (2020). Electoral and public opinion forecasts with social media data: A meta-analysis. *Information (Switzerland)*, *11*(4). Scopus. https://doi.org/10.3390/info11040187

Stegmaier, M., Jokinsky, S., & Lewis-Beck, M. S. (2023). The evolution of election forecasting models in the UK. *Electoral Studies*, *86*, 102694. https://doi.org/10.1016/j.electstud.2023.102694

Tsakalidis, A., Aletras, N., Cristea, A. I., & Liakata, M. (2018). Nowcasting the stance of social media users in a sudden vote: The case of the Greek referendum. En Proceedings of the 27th ACM International Conference on Information and Knowledge Management (CIKM '18) (pp. 367–376). New York, NY: ACM. https://doi.org/10.1145/3269206.3271783

Treen, K. M. D., Williams, H. T. P., & O'Neill, S. J. (2020). Online misinformation about climate change. *Wiley Interdisciplinary Reviews: Climate Change*, *11*(5). Scopus. https://doi.org/10.1002/wcc.665

Tucker, E. C., Capps, C. J., & Shamir, L. (2020). A data science approach to 138 years of congressional speeches. *Heliyon*, *6*(8). https://doi.org/10.1016/j.heliyon.2020.e04417

Tumasjan, A., Sprenger, T., Sandner, P., & Welpe, I. (2010). Predicting Elections with Twitter: What 140 Characters Reveal about Political Sentiment. *Proceedings of the International AAAI Conference on Web and Social Media*, *4*(1), Article 1. https://doi.org/10.1609/icwsm.v4i1.14009

We Are Social. (2024). Estas son las redes sociales preferidas por los colombianos: ¿cuáles utiliza usted? *Portafolio.co*. https://www.portafolio.co/tecnologia/estas-son-las-redes-sociales-mas-usadas-por-los-colombianos-616960

Weimann, G., & Masri, N. (2023). Research Note: Spreading Hate on TikTok. *Studies in Conflict and Terrorism*, *46*(5), 752-765. Scopus.

https://doi.org/10.1080/1057610X.2020.1780027

Whiteley, P. (1979). Electoral Forecasting from Poll Data: The British Case. *British Journal of Political Science*, *9*(2), 219-236. https://doi.org/10.1017/S0007123400001733

Zajonc, R. B. (2001). Mere exposure: A gateway to the subliminal. *Current Directions in Psychological Science*, *10*(6), 224-228. Scopus. https://doi.org/10.1111/1467-8721.00154

Zuloaga-Rotta, L., Borja-Rosales, R., Rodríguez Mallma, M. J., Mauricio, D., & Maculan, N. (2024). Method to Forecast the Presidential Election Results Based on Simulation and Machine Learning. *Computation*, *12*(3). Scopus. https://doi.org/10.3390/computation12030038

Anexo 1.

Facebook

account	date	FBPosts	FBLikes	FBShares	FBComments	FBLikesPPost	FBSharesPPost	FBCommentsPPost
Paz	2025-10-10	0	0	0	0	0	0	0
Paz	2025-10-11	0	0	0	0	0	0	0
Paz	2025-10-12	2	832	75	249	416	37,5	124,5
Paz	2025-10-13	13	5730	626	1450	440,7692308	48,15384615	111,5384615
Paz	2025-10-14	5	9433	928	2911	1886,6	185,6	582,2
Paz	2025-10-15	6	10579	579	3994	1763,166667	96,5	665,6666667
Paz	2025-10-16	0	0	0	0	0	0	0
Paz	2025-10-17	0	0	0	0	0	0	0
Paz	2025-10-18	0	0	0	0	0	0	0
Quiroga	2025-10-10	6	40640	2015	5027	6773,333333	335,8333333	837,8333333
Quiroga	2025-10-11	1	13880	1342	12588	13880	1342	12588
Quiroga	2025-10-12	4	52274	2664	6534	13068,5	666	1633,5
Quiroga	2025-10-13	15	119317	10081	20460	7954,466667	672,0666667	1364
Quiroga	2025-10-14	5	67218	3185	22535	13443,6	637	4507
Quiroga	2025-10-15	7	50924	4034	20629	7274,857143	576,2857143	2947
Quiroga	2025-10-16	2	7730	297	891	3865	148,5	445,5
Quiroga	2025-10-17	0	0	0	0	0	0	0
Quiroga	2025-10-18	0	0	0	0	0	0	0

Instagram

account	date	IGPosts	IGLikes	IGComments	IGLikesPPost	IGCommentsPPost
Paz	2025-10-10	1	133	7	133	7
Paz	2025-10-11	0	0	0	0	0
Paz	2025-10-12	3	100	53	33,33333333	17,66666667
Paz	2025-10-13	14	478	103	34,14285714	7,357142857
Paz	2025-10-14	5	375	101	75	20,2
Paz	2025-10-15	7	580	118	82,85714286	16,85714286
Paz	2025-10-16	0	0	0	0	0
Paz	2025-10-17	0	0	0	0	0
Paz	2025-10-18	0	0	0	0	0
Quiroga	2025-10-10	5	3202	71	640,4	14,2
Quiroga	2025-10-11	3	2114	127	704,6666667	42,33333333
Quiroga	2025-10-12	3	2063	54	687,6666667	18
Quiroga	2025-10-13	14	13427	283	959,0714286	20,21428571
Quiroga	2025-10-14	4	7005	183	1751,25	45,75
Quiroga	2025-10-15	4	6095	161	1523,75	40,25
Quiroga	2025-10-16	1	225	9	225	9
Quiroga	2025-10-17	0	0	0	0	0
Quiroga	2025-10-18	0	0	0	0	0

TikTok

account	date	TTKPosts	TTKLikes	TTKComments	TTKShares	TTKLikesPPost	TTKCommentsPPost	TTKSharesPPost
Paz	2025-10-10	1	3100	256	99	3100	256	99
Paz	2025-10-11	0	0	0	0	0	0	0
Paz	2025-10-12	0	0	0	0	0	0	0
Paz	2025-10-13	9	55885	3757	1423	6209,444444	417,4444444	158,1111111
Paz	2025-10-14	5	42469	1800	2389	8493,8	360	477,8
Paz	2025-10-15	9	10278	346	360	1142	38,44444444	40
Paz	2025-10-16	6	2996	133	63	499,3333333	22,16666667	10,5
Paz	2025-10-17	0	0	0	0	0	0	0
Paz	2025-10-18	0	0	0	0	0	0	0
Quiroga	2025-10-10	5	49841	3436	1730	9968,2	687,2	346
Quiroga	2025-10-11	4	13852	1151	640	3463	287,75	160
Quiroga	2025-10-12	2	18369	1483	924	9184,5	741,5	462
Quiroga	2025-10-13	3	41314	1441	14825	13771,33333	480,3333333	4941,666667
Quiroga	2025-10-14	4	46202	3013	5885	11550,5	753,25	1471,25
Quiroga	2025-10-15	8	173426	6126	9149	21678,25	765,75	1143,625
Quiroga	2025-10-16	2	3919	182	68	1959,5	91	34
Quiroga	2025-10-17	0	0	0	0	0	0	0
Quiroga	2025-10-18	0	0	0	0	0	0	0

Twitter

account	date	TTPosts	TTLikes	TTRetweets	TTLikesPPost	TTRetweetsPPost
Paz	########	1	260	38	260	38
Paz	########	0	0	0	0	0
Paz	########	7	417	106	59,57143	15,14286
Paz	########	0	0	0	0	0

Paz	########	1	219	34	219	34
Paz	########	1	166	45	166	45
Paz	########	0	0	0	0	0
Paz	########	0	0	0	0	0
Paz	########	0	0	0	0	0
Quiroga	########	3	20259	5524	6753	1841,333
Quiroga	########	0	0	0	0	0
Quiroga	########	0	0	0	0	0
Quiroga	########	0	0	0	0	0
Quiroga	########	0	0	0	0	0
Quiroga	########	0	0	0	0	0
Quiroga	########	1	733	69	733	69
Quiroga	########	0	0	0	0	0
Quiroga	########	0	0	0	0	0